

MAKİNE ÖĞRENMESİ ÖDEVİ

Referans Makale

Khushal, R. & Fatima, U. (2025).

*A novel fuzzy three-valued logic computational framework
in machine learning for medicine dataset.*

Computers in Biology and Medicine, 186, 109636.

Dersin Öğretim Üyesi

DR. Öğr. Üyesi Sinan UĞUZ

Öğrenci Ad – Soyad

Cudi ŞAMİ

Nujoud ALKHATIB

Shams AL HAJJI

1. Giriş

Kalp hastalığı, dünya genelinde en yaygın ölüm nedenlerinden biri olmaya devam etmektedir. Geleneksel makine öğrenmesi yaklaşımları, veri setlerindeki ikili (0/1) değişkenler üzerinde çalışarak yalnızca iki çıktı sınıfı üretmektedir: risk yok (0) veya risk var (1). Bu yaklaşım, gerçek hayattaki belirsizlikleri ve ara durumları göz ardı etmekte; dolayısıyla bireylerin erken uyarı almasını engellemektedir.

Bu çalışmada Khushal ve Fatima (2025) tarafından önerilen Bulanık Üç Değerli Mantık (Fuzzy Three-Valued Logic) mimarisi incelenmiş ve uygulanmıştır. Bu mimari; 0 (yok), 0.5 (olabilir) ve 1 (var) olmak üzere üç çıktı değeri sunarak belirsizlik durumlarını da kapsayan daha geniş bir tahmin aralığı sağlamaktadır. Böylece bireyler risk oluşmadan uyarılarak gerekli yaşam tarzı değişikliklerini yapabilmektedir.

Ödevin temel amaçları şunlardır:

- Ham veriyi SQLite veritabanında düzenli biçimde depolamak
- Sigara, alkol ve fiziksel aktivite değişkenlerine bulanık dönüşüm (fuzzification) uygulamak
- 7 farklı ML algoritmasını hem orijinal hem de bulanık değiştirilmiş veri setiyle eğitmek ve karşılaştırmak
- Streamlit ile kullanıcı dostu bir tahmin arayüzü geliştirmek

2. Metodoloji

2.1 Veri Seti ve Ön İşleme

Çalışmada Kaggle platformundan elde edilen Cardiovascular Disease (Kalp Hastalığı Tahmini) veri seti kullanılmıştır. Veri setine ilişkin temel bilgiler şu şekildedir:

- Toplam kayıt sayısı: 70.000 birey
- Kaynak: Kaggle — sulianova/cardiovascular-disease-dataset
- Girdi değişkeni türleri: Kategorik ve sayısal (11 değişken)
- Çıktı değişkeni: İkili (cardio: 0 veya 1)

Ön işleme adımları sırasıyla şu şekilde uygulanmıştır: gereksiz id sütunu kaldırılmış, yaş değerleri gün biriminden yıl birimine dönüştürülmüş, boy ve kilo sütunlarından BMI hesaplanmış, ardından bu iki sütun çıkarılmıştır. Son olarak aykırı değerler temizlenmiştir: sistolik basınç 80–200 mmHg, diyastolik basınç 40–140 mmHg, BMI 10–60 ve yaş 1–100 aralıklarının dışındaki kayıtlar veri setinden çıkarılmıştır. Temizleme işlemi sonucunda 70.000 kayıttan 68.614 kayıt kalmıştır. Tüm ham ve işlenmiş veriler SQLite veritabanında (heart_disease.db) raw_data ve processed_data tablolarında saklanmıştır.

2.2 Bulanık Üç Değerli Mantık Uygulaması

Makaledeki Tablo 8 ve Denklem (1) esas alınarak üç ikili değişken karşılaştırılmış ve tek bir 'Diğer Faktörler (θ)' sütununa dönüştürülmüştür. Kullanılan değişkenler şunlardır: sigara (x), alkol (y) ve fiziksel aktivite (z — negasyonu alınmış $\neg z$). Dönüşüm kuralı aşağıdaki gibi tanımlanmıştır:

$$\begin{aligned}\theta = 0 &\rightarrow x = y = \neg z = 0 \text{ (hiçbir risk faktörü yok)} \\ \theta = 1 &\rightarrow x = y = \neg z = 1 \text{ (tüm risk faktörleri mevcut)} \\ \theta = 0.5 &\rightarrow \text{diğer tüm durumlar (belirsizlik)}\end{aligned}$$

Fiziksel aktivite değişkeninin negasyonu alınmıştır; çünkü sigara ve alkol değişkenlerinde 1 kötü alışkanlığı temsil ederken, fiziksel aktivitede 1 iyi alışkanlığı temsil etmektedir. Bu tutarsızlığı gidermek amacıyla $\neg z$ kullanılmıştır. Fuzzification sonucunda elde edilen dağılım aşağıdaki tabloda gösterilmektedir:

Değişken	Değer	Kayıt Sayısı
Other Factors (θ)	0.0 — Risk Yok	48.513
Other Factors (θ)	0.5 — Belirsiz	19.824
Other Factors (θ)	1.0 — Risk Var	277
Yaş Kategorisi	0 — Eşik Altı	28.362
Yaş Kategorisi	1 — Eşik Üstü	40.252

Tabloda görüldüğü üzere, bireylerin büyük çoğunluğu (48.513 kişi) hiçbir davranışsal risk faktörü taşımazken, 19.824 kişi belirsizlik sınıfında ($\theta = 0.5$) yer almaktadır. Yalnızca 277 kişide tüm risk faktörleri aynı anda mevcut bulunmaktadır.

2.3 Yaş Kategorilendirmesi ve Karar Kuralları

Makaleye göre yaş değişkeni, cinsiyete bağlı olarak iki kategoriye ayrılmıştır. Kadınlar için 55 yaş eşiği kullanılırken, erkekler için 45 yaş eşiği esas alınmıştır. Bu eşikler kalp hastalığı risk faktörlerine ilişkin tıp literatürüne dayanmaktadır. Elde edilen dağılıma göre 40.252 birey eşik üstü (kategori 1), 28.362 birey ise eşik altı (kategori 0) grubunda yer almaktadır.

Yaş kategorisi ve Diğer Faktörler (θ) birleştirilerek 12 IF-THEN karar kuralı oluşturulmuş ve çıktı değişkeni üç sınıfa dönüştürülmüştür. Tasarlanan kurallar aşağıdaki tabloda özetlenmektedir:

Kural	Koşul	Sonuç
Kural 1	Kadın, yaş < 55, diğer faktörler = 0	Risk YOK (0)
Kural 2	Kadın, yaş < 55, diğer faktörler = 0.5	Risk OLABİLİR (0.5)
Kural 3	Kadın, yaş < 55, diğer faktörler = 1	Risk VAR (1)
Kural 4	Kadın, yaş $\geq$ 55, diğer faktörler = 0	Risk OLABİLİR (0.5)
Kural 5	Kadın, yaş $\geq$ 55, diğer faktörler = 0.5	Risk OLABİLİR (0.5)
Kural 6	Kadın, yaş $\geq$ 55, diğer faktörler = 1	Risk VAR (1)
Kural 7	Erkek, yaş < 45, diğer faktörler = 0	Risk YOK (0)
Kural 8	Erkek, yaş < 45, diğer faktörler = 0.5	Risk OLABİLİR (0.5)
Kural 9	Erkek, yaş < 45, diğer faktörler = 1	Risk VAR (1)
Kural 10	Erkek, yaş $\geq$ 45, diğer faktörler = 0	Risk OLABİLİR (0.5)
Kural 11	Erkek, yaş $\geq$ 45, diğer faktörler = 0.5	Risk OLABİLİR (0.5)
Kural 12	Erkek, yaş $\geq$ 45, diğer faktörler = 1	Risk VAR (1)

Makine öğrenmesi sınıflandırıcıları 0.5 değerini doğrudan tahmin edemediğinden bu değer 2 olarak kodlanmış ve problem üç sınıflı (0, 1, 2) bir sınıflandırma görevine dönüştürülmüştür

2.4 Model Eğitimi

Yedi farklı makine öğrenmesi algoritması hem orijinal (Normal) hem de bulanık değiştirilmiş (Modified) veri setleri üzerinde %80 eğitim – %20 test ayrımıyla eğitilmiştir. Kullanılan algoritmalar ve makale Tablo 7'ye göre belirlenen hiperparametreleri şu şekildedir:

- Gaussian Naive Bayes (GNB) — varsayılan parametreler
- Destek Vektör Makinesi (SVM) — kernel: linear, C: 1
- AdaBoost — learning_rate: 1, n_estimators: 100
- Karar Ağacı (DT) — criterion: gini, max_depth: 10, min_samples_leaf: 100
- K-En Yakın Komşu (KNN) — metric: minkowski, n_neighbors: 15, weights: uniform
- Rastgele Orman (RF) — bootstrap: False, max_depth: 10, max_features: 4, n_estimators: 25
- Gradyan Artırma (GB) — max_depth: 3, learning_rate: 0.1, n_estimators: 90

Her iki veri seti için doğruluk (accuracy), kesinlik (precision) ve hesaplama süresi metrikleri hesaplanmış; sonuçlar SQLite veritabanının model_results tablosuna kaydedilmiştir.

2.5 Streamlit Arayüzü


Kullanıcıların cinsiyet, yaş, sigara, alkol ve fiziksel aktivite bilgilerini girebileceği etkileşimli bir web arayüzü Streamlit kütüphanesi kullanılarak geliştirilmiştir. Sistem arka planda bulanık üç değerli mantık motorunu çalıştırmakta, 12 karar kuralını uygulamakta ve kullanıcıya üç farklı sonuç sunmaktadır: Risk Yok (yeşil), Risk Olabilir (sarı) ve Risk Var (mor). Arayüzde ayrıca θ değeri, yaş kategorisi ve risk skoru gibi hesaplama detayları da görüntülenmektedir.

3. Bulgular

3.1 Doğruluk (Accuracy) Karşılaştırması

Tüm algoritmaların doğruluk değerleri, orijinal ve bulanık değiştirilmiş veri setleri üzerinde hesaplanmıştır. Gerçek uygulama sonuçları aşağıdaki tabloda sunulmaktadır:

Veri Seti	GNB	SVM	AdaBoost	DT	KNN	RF	GB
Normal	0.71	0.73	0.73	0.73	0.72	0.74	0.74
Modified	1.00	1.00	1.00	1.00	1.00	1.00	1.00



Şekil 1 — Normal ve Modified veri setlerinde tüm algoritmalara ait Accuracy ve Precision karşılaştırma grafiği.

Sonuçlar incelendiğinde, normal veri setinde algoritmaların doğruluk değerlerinin 0.71 (GNB) ile 0.74 (RF ve GB) arasında değiştiği görülmektedir. Bulanık değiştirilmiş veri setinde ise tüm algoritmalar 1.00 doğruluğa ulaşmıştır. Bu iyileşme, bulanık mantığın özellik mühendisliğine sağladığı katkıyı açıkça ortaya koymaktadır.

3.2 Kesinlik (Precision) Karşılaştırması

Makro ortalama kesinlik değerleri aşağıdaki tabloda gösterilmektedir:

Veri Seti	GNB	SVM	AdaBoost	DT	KNN	RF	GB
Normal	0.72	0.73	0.73	0.74	0.72	0.74	0.74
Modified	1.00	1.00	1.00	1.00	1.00	1.00	1.00

Normal veri setinde kesinlik değerleri 0.72 ile 0.74 arasında kalırken, bulanık değiştirilmiş veri setinde tüm modeller 1.00 kesinlik değerine ulaşmıştır. Bu sonuç, yanlış pozitif oranının sıfıra indiğini göstermekte olup klinik uygulamalar açısından büyük önem taşımaktadır.

3.3 Hesaplama Süresi Karşılaştırması

Bulanık dönüşüm işlemi özellik sayısını önemli ölçüde azaltmış ve bu durum hesaplama sürelerine de olumlu yansımıştır:

Veri Seti	GNB	SVM	AdaBoost	DT	KNN	RF	GB
Normal (s)	0.05	469.52	1.76	0.11	0.89	1.34	3.51
Modified (s)	0.01	0.08	1.00	0.01	1.27	0.14	2.11

En belirgin iyileşme SVM modelinde gözlemlenmiştir: 469.52 saniyeden yalnızca 0.08 saniyeye düşerek yaklaşık 5.869 kat hızlanma sağlanmıştır. RF modeli 1.34 saniyeden 0.14 saniyeye, DT modeli ise 0.11 saniyeden 0.01 saniyeye gerilemiştir. Bulanık değiştirilmiş veri setinde tüm modeller 2.11 saniyenin altında sonuç üretmiştir.

3.4 Streamlit Arayüzü Çıktıları

Geliştirilen Streamlit arayüzü üç farklı risk senaryosunu başarıyla görselleştirmektedir. Aşağıda her senaryoya ait ekran görüntüleri yer almaktadır.

Şekil 2 — Risk Yok (Güvenli)

Şekil 2 — Risk Yok (Güvenli) Senaryosu: Sigara içmeyen, alkol kullanmayan ve fiziksel aktivite yapan bireyde sistem "RİSK YOK" çıktısı üretmektedir.

The screenshot shows a web browser window with the address bar displaying 'Not secure 10.113.85.99:8501'. The page title is 'Kalp Risk Analizi' and the subtitle is 'FUZZY THREE-VALUED LOGIC SİSTEMİ'. The form is divided into two sections: 'KİŞİSEL BİLGİLER' (Personal Information) and 'YAŞAM TARZI' (Lifestyle). The 'KİŞİSEL BİLGİLER' section includes 'Cinsiyet' (Gender) set to 'Kadın', 'Yaş' (Age) set to '45', and 'Fiziksel Aktivite' (Physical Activity) set to 'Evet'. The 'YAŞAM TARZI' section includes 'Sigara' (Cigarettes) set to 'Evet', 'Alkol' (Alcohol) set to 'Evet', and 'Fiziksel Aktivite' (Physical Activity) set to 'Evet'. A purple button labeled 'ANALİZ ET' (Analyze) is located below the form. Below the button, a yellow box with a warning icon and the text 'RİSK OLABİLİR' (Risk Possible) is displayed. The text below the box reads: 'Kalp hastalığı riski belirsiz. Riski yüksek algılamak hayatınıza olumsuz etkiler.' (Heart disease risk is uncertain. Risk is high perception can have negative effects on your life.) At the bottom, there is a link 'Hesaplama Detayları' (Calculation Details).

Şekil 3 — Risk Olabilir (Belirsiz)

Şekil 3 — Risk Olabilir (Belirsiz) Senaryosu: Sigara içen, alkol kullanan ancak fiziksel aktivite yapan bireyde sistem "RİSK OLABİLİR" çıktısı üretmektedir. Bu durum bulanık mantığın 0.5 sınıfına karşılık gelmektedir.

The screenshot shows the same web browser window as before, but with different input values. The 'KİŞİSEL BİLGİLER' section remains the same. The 'YAŞAM TARZI' section now has 'Sigara' (Cigarettes) set to 'Evet', 'Alkol' (Alcohol) set to 'Evet', and 'Fiziksel Aktivite' (Physical Activity) set to 'Hayır' (No). The purple button 'ANALİZ ET' (Analyze) is still present. Below the button, a purple box with a red circle icon and the text 'RİSK VAR' (Risk Present) is displayed. The text below the box reads: 'Kalp hastalığı riski yüksek. Lütfen en kısa zamanda bir doktora başvurun.' (Heart disease risk is high. Please consult a doctor as soon as possible.) At the bottom, there is a link 'Hesaplama Detayları' (Calculation Details).

Şekil 4 — Risk Var (Tehlikeli)

Şekil 4 — Risk Var (Tehlikeli) Senaryosu: Sigara içen, alkol kullanan ve fiziksel aktivite yapmayan bireyde sistem "RİSK VAR" çıktısı üretmektedir.

4. Sonuç ve Tartışma

Elde edilen bulgular, Khushal ve Fatima (2025) tarafından önerilen hibrit modelin etkinliğini başarıyla doğrulamaktadır. Normal veri setindeki %71–%74 doğruluk oranı, bulanık dönüşüm sonrasında %100'e yükselmiştir. Bu iyileşmenin temel nedeni, üç ayrı ikili değişkenin (sigara, alkol, fiziksel aktivite) tek bir anlamlı değişkene (θ) indirgenmesidir. Bu dönüşüm hem sınıf ayrımını netleştirmiş hem de özellik uzayını sadeleştirmiştir. Ancak modified veri setindeki belirgin sınıf dengesizliği ($\theta=0$: 48.513, $\theta=0.5$: 19.824, $\theta=1$: 277) yüksek doğruluk değerlerini etkilemiş olabileceğinden bu sonuçlar dikkatli yorumlanmalıdır.

Hesaplama süresi açısından da kayda değer iyileşmeler gözlemlenmiştir. SVM algoritması 469.52 saniyeden 0.08 saniyeye inerek yaklaşık 5.869 kat hızlanma sergilemiştir. Bu durum, bulanık özellik mühendisliğinin yalnızca doğruluğu değil, hesaplama verimliliğini de önemli ölçüde artırdığını göstermektedir.

Klinik açıdan değerlendirildiğinde, 0.5 (Risk Olabilir) sınıfının eklenmesi özellikle önem taşımaktadır. Bu ara sınıf; henüz kalp hastalığı riski oluşmamış ancak davranışsal risk faktörleri nedeniyle risk sınırında olan bireylerin erken uyarılmasını sağlamaktadır. Yöntemin temel sınırlılığı ise bulanık değişken seçimi ve karar kurallarının tasarlanmasında alan bilgisi gerektirmesidir.

Temel bulgular aşağıda özetlenmektedir:

- 70.000 kayıtlık ham veri, ön işleme adımları sonucunda 68.614 temiz kayda indirgenmiştir.
- Fuzzification işlemi ile θ değişkeni oluşturulmuş; bireylerin 48.513'ü risk yok (0), 19.824'ü belirsiz (0.5), 277'si ise risk var (1) sınıfına atanmıştır.
- Normal veri setinde 0.71–0.74 arasında seyreden doğruluk oranı, bulanık değiştirilmiş veri setinde tüm algoritmalar için 1.00'e yükselmiştir.
- SVM hesaplama süresi 469.52 saniyeden 0.08 saniyeye düşmüştür.
- Geliştirilen Streamlit arayüzü, 12 bulanık kural kullanarak kullanıcılara gerçek zamanlı risk tahmini sunmaktadır.
- Tüm veriler SQLite veritabanında sistematik biçimde saklanmıştır.

Bu çalışma, bulanık mantığın makine öğrenmesiyle entegrasyonunun yalnızca sınıflandırma doğruluğunu artırmakla kalmayıp hesaplama verimliliğini ve klinik yorumlanabilirliği de önemli ölçüde iyileştirdiğini göstermektedir.

Kaynakça

Khushal, R. & Fatima, U. (2025). A novel fuzzy three-valued logic computational framework in machine learning for medicine dataset. *Computers in Biology and Medicine*, 186, 109636. <https://doi.org/10.1016/j.compbiomed.2024.109636>

Kaggle. (2024). Cardiovascular Disease Dataset.
<https://www.kaggle.com/datasets/sulianova/cardiovascular-disease-dataset>